

Sistemas de recomendación

[8.1] ¿Cómo estudiar este tema?

[8.2] Introducción. Tipos de recomendadores y aplicaciones

[8.3] Recomendación colaborativa. Filtrado colaborativo basado en usuarios. Filtrado colaborativo basado en ítems

[8.4] Recomendación basada en contenido. Representación del contenido y similitud entre elementos

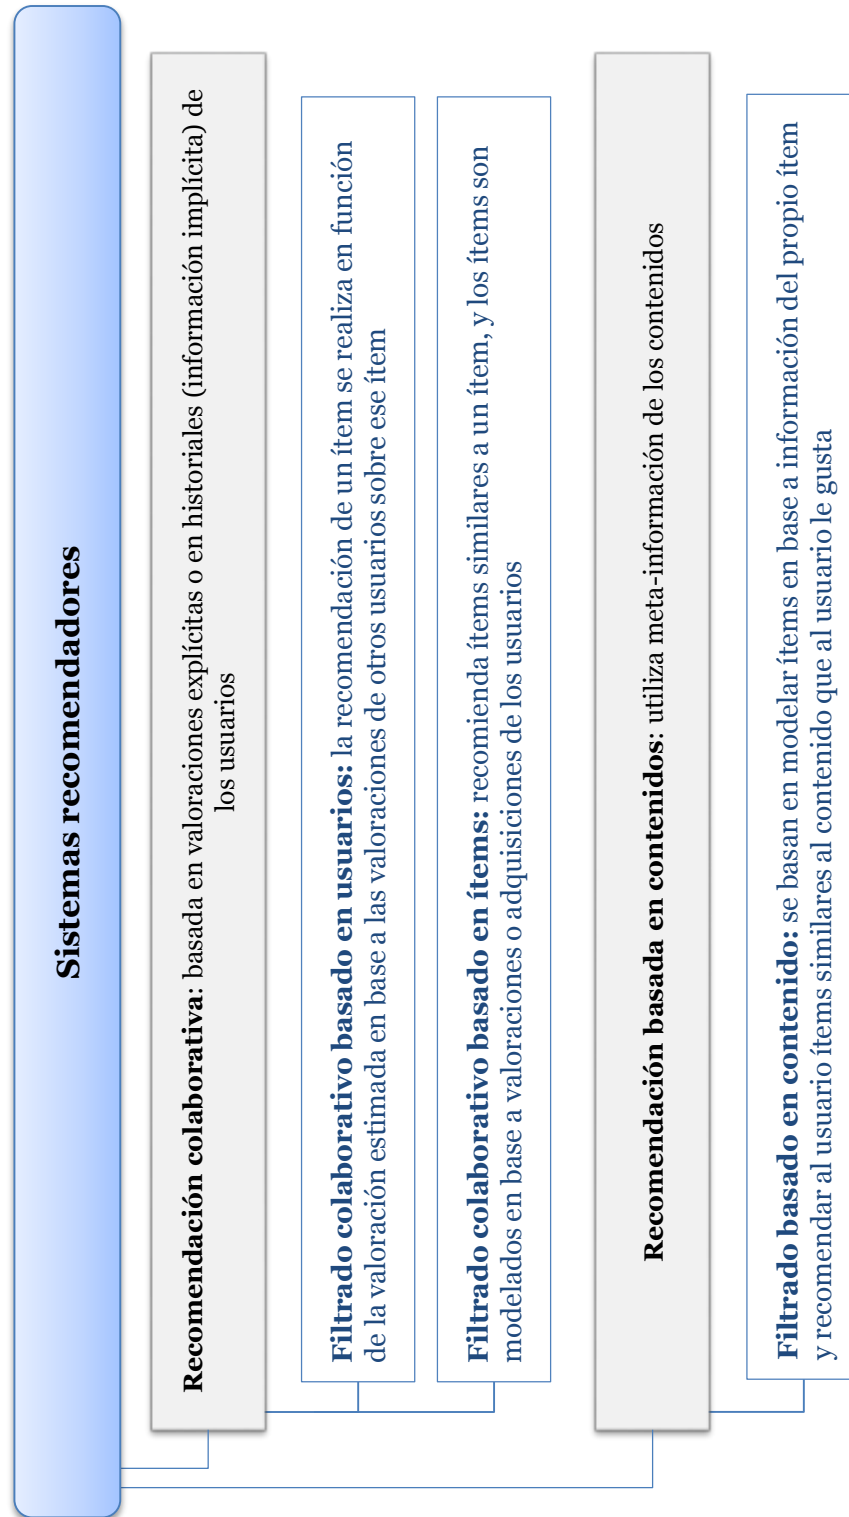
[8.5] Referencias



8

TEMA

Esquema



Ideas clave

8.1. ¿Cómo estudiar este tema?

Para estudiar este tema deberás leer las **Ideas clave** que se presentan a continuación. Puedes completar el estudio visualizando la lección magistral.

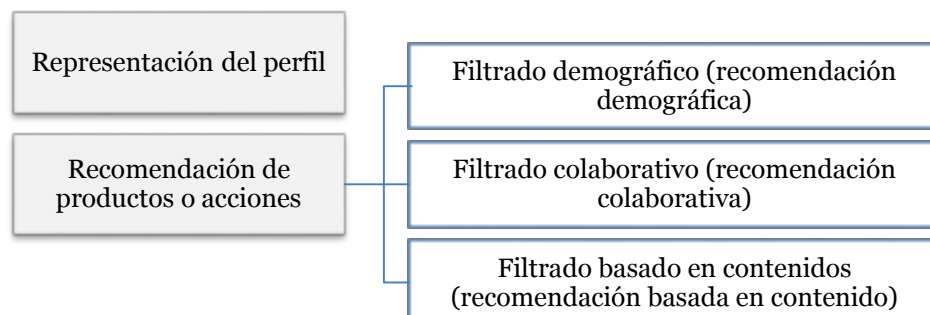
Al finalizar el estudio de este tema serás capaz de:

- » Describir los dos tipos de recomendadores más significativos: basados en filtrado colaborativo y basados en contenido.
- » Aplicar técnicas de recomendación para la resolución de problemas de recomendación.
- » Identificar aplicaciones prácticas de recomendadores.

8.2. Introducción. Tipos de recomendadores y aplicaciones

La gran cantidad de contenidos disponibles en Internet en la actualidad supone que los usuarios se encuentren frecuentemente en situaciones en las que han de elegir entre un gran número de opciones y llegan a sentirse abrumados o perdidos. Por lo tanto, cualquier técnica que permita **clasificar, ordenar o filtrar la información disponible** es de gran interés en la actualidad. Estas técnicas se basan, por ejemplo, en modelar contenidos así como preferencias y comportamientos de usuarios, creando estereotipos, y filtrando la información en función de los estereotipos.

Montaner et al (2003) describe los principales componentes y procesos de los sistemas recomendadores:



- » **Representación del perfil.** El primer paso al crear un sistema recomendador es diseñar cómo se va a representar el perfil del usuario, esto es, qué información de los usuarios se va a tener en cuenta para las recomendaciones y, por tanto, hay que capturar.

Cuando un usuario interactúa con el navegador, si se captura la información adecuada (por ejemplo, un historial de compras o de navegación) y se interpreta correctamente, se puede conseguir un gran éxito en las recomendaciones, ya que a partir de esta información se pueden deducir preferencias, gustos, hábitos y comportamientos de los usuarios. Habrá que utilizar, por tanto, técnicas para generar inicialmente los perfiles de los usuarios, y posteriormente actualizarlos y mantenerlos.

- » **Recomendación de productos o acciones** a los usuarios mediante una técnica de filtrado que definirá el tipo de recomendación:

- **Filtrado demográfico (recomendación demográfica):** utiliza descripciones de personas para aprender la relación entre un ítem de información y el tipo de personas que les gusta ese ítem. Este tipo de técnicas requieren recopilación de datos personales sobre el usuario para clasificarlo demográficamente en un estereotipo.
- **Filtrado colaborativo (recomendación colaborativa):** realiza recomendaciones usualmente en base a la retroalimentación o el *feedback* que los conjuntos de usuarios dan explícitamente sobre un ítem. También se pueden basar en información capturada implícitamente como, por ejemplo, el historial de compras de los usuarios.
- **Filtrado basado en contenidos (recomendación basada en contenido):** utiliza metainformación de los contenidos de los ítems para aprender la relación entre un usuario y esa metainformación.

Por lo tanto, se ha de escoger una técnica de filtrado y una técnica de emparejamiento, bien entre estereotipo y contenidos (filtrado demográfico), bien entre el perfil de usuario y el contenido (filtrado basado en contenido), o bien entre perfiles de usuarios (filtrado colaborativo).

Para la **representación del perfil** se pueden utilizar técnicas de inteligencia artificial estudiadas en la asignatura, tales como árboles de decisión, reglas inducidas, redes neurológicas o redes bayesianas. Las reglas de asociación, tal y como se comentó en el tema correspondiente, se utilizan precisamente en estos sistemas para la recomendación de productos a partir de otros productos que se han adquirido.

En aplicaciones de comercio electrónico se suele utilizar un historial de las compras y las valoraciones que los usuarios dan sobre los productos comprados para generar reglas de asociación. Este tipo de información es también utilizada cuando se utilizan técnicas de filtrado. Algunos sistemas mantienen matrices de valoraciones usuario-ítem como representación del perfil, como típicamente hacen los sistemas de filtrado colaborativo.



Además, los sistemas recomendadores utilizan a veces técnicas de *clustering* para generar grupos y agregar el perfil del usuario que se está analizando a un determinado clúster de perfiles similares.

Inicialmente, a la hora de generar los perfiles, algunos sistemas simplemente los generan vacíos y, según el usuario interacciona, los van completando; mientras que otros sistemas, en base a la información disponible del usuario (por ejemplo la información que el usuario aporta al darse de alta en un sistema), tratan de clasificarlo en un determinado estereotipo (como típicamente realizan los sistemas de filtrado demográfico).

Dado que los intereses de los usuarios cambian y, según transcurre el tiempo e interactúan con los sistemas, se puede conseguir más información de los mismos, por lo que se han de actualizar los perfiles. Algunos de estos sistemas solicitan retroalimentación al usuario de manera explícita y suelen dar muy buenos resultados siempre que los usuarios se animen a realizar valoraciones de los productos. Otros sistemas capturan las interacciones de los usuarios y actualizan su perfil en base a estas.

El tipo de información que implícitamente se puede obtener de estas interacciones es, por ejemplo, el historial de compras, el historial de navegación, el tiempo que un usuario está en cada página, etc. Hay sistemas que utilizan tanto información explícita como implícita.

A la hora de utilizar esta información para tomar decisiones, dado que las últimas interacciones pueden reflejar en mayor medida los intereses del usuario actuales que las interacciones antiguas, hay sistemas que ponderan estas interacciones.

El problema de los sistemas de filtrado demográfico es que suelen dar recomendaciones muy generales, no siendo suficientemente personalizadas, además no suelen adaptarse a los cambios en los intereses de los usuarios. En los siguientes apartados se detallan los sistemas de recomendación colaborativos y los sistemas de recomendación basados en contenidos.

Previamente a entrar en el detalle de cada tipo de técnica se enumeran algunos ejemplos de aplicación de los sistemas recomendadores:

- » **Comercio electrónico.** Amazon es un claro y popular ejemplo de comercio electrónico que recomienda a los usuarios nuevos productos a adquirir. Cuando un usuario visita la página de un producto, Amazon le recomienda productos adquiridos por otros usuarios que han comprado el producto que el usuario está visitando.
- » **Webs de música o vídeos:** recomiendan a los usuarios música o vídeos en base a la similitud con contenidos ya visitados o en base a la similitud con otros usuarios que comparten gustos musicales.
- » **Noticias:** sistemas que recomiendan noticias de interés a un usuario en base a sus intereses, historial de noticias previamente visitadas, etc.

En la actualidad, el gran auge de las redes sociales y de los sistemas colaborativos en red hace que los datos de conectividad entre usuarios resulten una base verdaderamente útil para llevar a cabo un eficaz filtrado de contenidos y mejora de la adaptabilidad de los mismos al usuario.

8.3. Recomendación colaborativa. Filtrado colaborativo basado en usuarios. Filtrado colaborativo basado en ítems

Los sistemas de **recomendación colaborativa** recomiendan los ítems a un usuario basándose en las preferencias o historial de otros usuarios.

Estos sistemas utilizan técnicas de filtrado colaborativo y se pueden distinguir diversos tipos de técnicas como por ejemplo:

- » **Filtrado colaborativo basados en usuarios:** estiman la valoración que un usuario daría a un determinado contenido para decidir su recomendación. La similitud entre usuarios la miden en base a las valoraciones de los ítems realizadas previamente, y las puntuaciones de ítems no visitados por un usuario se predicen en función de la valoración que otros usuarios, con un alto grado de similitud al usuario en cuestión, han otorgado al citado contenido.
- » **Filtrado colaborativo basado en ítems:** Calculan la similitud entre ítems. Estos ítems son descritos en base a datos de los usuarios, por ejemplo, las valoraciones dadas por los diferentes usuarios al ítem, o las adquisiciones realizadas o no realizadas por los distintos usuarios. Por eso, sigue considerándose recomendación del tipo colaborativa. Al usuario se le recomiendan los ítems más similares a un ítem adquirido o a un ítem que se está visitando.

De acuerdo a Montaner et al (2003), se suelen aplicar las siguientes medidas para calcular la similitud entre usuarios, también utilizadas para medir similitud entre ítems:

- » **Similitud coseno** (*Cosine similarity*): mide la similitud entre dos vectores, calculando el coseno del ángulo entre ambos. Si vale 1, ambos vectores son similares totalmente y, si vale 0, son totalmente distintos. El vector estará formado de elementos del perfil del usuario o atributos del ítem.
- » **Medidas de correlación:** por ejemplo, los coeficientes de correlación de Pearson o de Spearman se pueden utilizar para comparar usuarios a partir de sus valoraciones numéricas.

Para llevar a cabo una recomendación de los contenidos a cada usuario es importante conocer en todo momento la valoración que este daría a cada contenido. En algunas ocasiones dicha valoración puede estar disponible en los datos almacenados en el sistema, pero en otros casos se ha de predecir dicha valoración teniendo en cuenta el comportamiento del resto de los usuarios del sistema.

Uno de los algoritmos de predicción más empleado y muy simple en los sistemas de **Filtrado Colaborativo basado en usuario** es **Slope One**. Dicho algoritmo cuenta con una matemática muy sencilla pero a la vez eficiente como se puede consultar en el artículo «*Collaborative Filtering and Inference Rules for Context-Aware Learning Object Recommendation*» (Lemire et al, 2005).

La idea que subyace de la aplicación de este algoritmo, en su versión más simple, es que dadas las valoraciones de dos ítems correspondientes al usuario A y la valoración de uno de estos ítems por parte del usuario B se pueda predecir la valoración correspondiente al ítem que falta de valorar por parte del usuario B. Este ejemplo se puede escalar a un mayor número de usuarios y existen distintas versiones del algoritmo para perfeccionar los resultados (como pueden ser *Weighted Slope One* y *Bipolar Slope One*).

Con un ejemplo muy sencillo se ilustra el algoritmo Slope One. Este ejemplo se basa en el expuesto por los creadores del algoritmo (Lemire et al, 2005). El algoritmo **Slope One** se basa en la siguiente función de predicción de la valoración de un ítem:

$$f(x) = x + b$$

Siendo b la diferencia media de valoraciones entre ítems.

	Ítem 1	Ítem 2
María	4/10	---
Pablo	2/10	5/10
Luis	3/10	7/10
Alicia	6/10	8/10

Tabla 1. Valoraciones de los usuarios

Se tiene un comercio en línea en el que los ítems reciben una valoración unidimensional, tal y como se muestra en la Tabla 1. El usuario María no ha adquirido el ítem 2 y el sistema recomendador ha de decidir si recomendar ese ítem a María o no. Como sí existe la valoración de María al ítem 1, para predecir su valoración desconocida al ítem 2, el sistema se va a basar en la diferencia media entre la valoración dada al ítem 2 y la valoración dada al ítem 1 por otros usuarios. Esta media es 3 luego el sistema predice que María valorará el ítem 2 con un 7/10.

El algoritmo **Weighted Slope One**, como su propio nombre indica, utiliza pesos para tener en cuenta el hecho de que la información que se obtiene a partir de aquellos ítems que han recibido más valoraciones es más fiable.

El algoritmo *Slope One* se basa en tener valoraciones sobre los ítems. Si no se tienen estas valoraciones se puede tener en cuenta otra información como, por ejemplo, si un ítem ha sido adquirido o no. Por tanto, la información sobre cada ítem en este caso es binaria. Se describe por ejemplo el algoritmo de **filtrado colaborativo ítem-a-ítem** utilizado por Amazon (Linden et al, 2003), que es se puede considerar **filtrado colaborativo basado en ítem**.

Este algoritmo se centra en encontrar ítems similares y, para ello, construye una tabla de ítems similares que incluye ítems que los usuarios tienden a comprar conjuntamente. La similitud la calcula con la medida de similitud coseno y la tabla se crea en base al algoritmo mostrado en la figura 1.

```

Para cada ítem  $I_1$ 
  Para cada cliente  $C$  que compró  $I_1$ 
    Por cada ítem  $I_2$  comprado por el cliente  $C$ 
      Registra que el cliente  $C$  compró  $I_1$  e  $I_2$ 
  Por cada ítem  $I_2$ 
    Calcula la similitud entre  $I_1$  e  $I_2$ 

```

Figura 1. Algoritmo de filtrado colaborativo ítem-a-ítem

Por ejemplo, en la tabla 2 se muestra una tabla con los datos de compras de 3 usuarios para 3 ítems. Un valor 0 significa que el producto no ha sido adquirido y un valor 1 significa que sí ha sido adquirido.

	Ítem 1		Item 2	Ítem 3
María	0		1	0
Pablo	0		1	1
Luis	1		0	1

Tabla 2. Compras de los usuarios

La medida de similitud del coseno tiene la siguiente expresión:

$$similitud = \cos(\vec{A}, \vec{B}) = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|} = \frac{\sum_{i=1}^n A_i \cdot B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \cdot \sqrt{\sum_{i=1}^n (B_i)^2}}$$

Por tanto, para el ejemplo de la tabla 2, la similitud entre cada dos ítems en función de las compras realizadas por los diferentes usuarios de esos ítems se calcula como:

$$similitud (Item 1, Item 2) = \frac{(0,0,1) \cdot (1,1,0)}{\|(0,0,1)\| \cdot \|(1,1,0)\|} = 0$$

$$similitud (Item 1, Item 3) = \frac{(0,0,1) \cdot (0,1,1)}{\|(0,0,1)\| \cdot \|(0,1,1)\|} = \frac{1}{\sqrt{2}} = 0.71$$

$$similitud (Item 2, Item 3) = \frac{(1,1,0) \cdot (0,1,1)}{\|(1,1,0)\| \cdot \|(0,1,1)\|} = \frac{1}{2} = 0.5$$

En la tabla 3 se muestra la matriz de similitud resultante.

	Ítem 1	Item 2	Ítem 3
Item 1	1	0	0.71
Item 2	0	1	0.5
Item 3	0.71	0.5	1

Tabla 3. Matriz Similitud

Por lo tanto, un usuario que visita la página del ítem 1, recibirá una recomendación del ítem 3, que es el más similar según la matriz de similitud. Un usuario que visite el ítem 2, recibirá una recomendación del ítem 3. Por último un usuario que visite el ítem 3, recibirá una recomendación del ítem 1.

Los sistemas de filtrado colaborativo basados en usuario presentan el problema de que puede haber ítems sin tener valoraciones, con lo cual no se tiene información a priori para recomendarlos.

Para resolver este problema se podría combinar técnicas de filtrado colaborativo basado en usuario y basado en ítem. Se podría utilizar alguna técnica de recomendación basada en ítem hasta que el ítem es valorado por el necesario número de usuarios. Por otra parte, en aquellos sistemas con gran oferta de contenidos puede suceder que cada contenido presente pocas valoraciones y, por tanto, este tipo de sistemas en general requieren de un gran número de usuarios para dar buenos resultados.

8.4. Recomendación basada en contenido. Representación del contenido y similitud entre elementos

Los sistemas de recomendación basada en contenidos recomiendan a los usuarios ítems que son similares a otros ítems que al usuario le han gustado previamente. Muchos de estos sistemas recomiendan ítems que contienen cierta información textual estructurada acompañando a los contenidos (metadatos).

Esto permite, por ejemplo, conociendo que a un usuario le gusta la música rock y que escucha muchos grupos de los años 70, recomendar ítems del mismo estilo musical, de un mismo grupo que el usuario ya ha escuchado previamente o de grupos de rock de los años 70, etc. Por tanto, estos sistemas pueden utilizar tanto un perfil de preferencias explícitamente expuestas por el usuario (si existe), como la historia de contenidos visitados o las valoraciones a los contenidos explícitamente aportadas por el usuario.

Los **recomendadores basados en contenido** proporcionan recomendaciones comparando representaciones que describen a un ítem con representaciones de contenido que al usuario le gusta.

Se pueden distinguir tres componentes principales en los recomendadores de contenidos (Lops et al, 2011):

Analizador de contenido	Perfil del alumno	Filtrado
Es necesario si los contenidos no están acompañados de metadatos o información estructurada.	Recopila datos de las preferencias del usuario y generaliza para construir el perfil del usuario. Habitualmente se utilizan técnicas de aprendizaje automático para realizar esa generalización y clasificar al usuario en un determinado perfil.	Sugiere ítems al usuario comparando su perfil con las representaciones de los contenidos.

Como se ha comentado, los ítems o contenidos requieren ir acompañados de metadatos o alguna información estructurada que los describa para poder ser recomendados. Sucede en muchas ocasiones que esta información es extraída mediante un analizador de contenidos y no tiene un formato bien definido o estructurado (atributos con valores bien definidos) (Lops et al, 2011). Muchos sistemas de recomendación representan el contenido mediante vectores de n dimensiones donde cada dimensión corresponde a un término del vocabulario empleado para describir los contenidos.

Los contenidos se pueden representar con un vector de pesos, donde cada peso indica el grado de asociación entre el contenido y el término. Esto es una representación basada en el espacio de vectores (**VSM – Vector Space Model**).

Se requiere, por tanto, ponderar términos y medir la similitud entre los vectores. Un modelo muy utilizado en la recomendación de documentos es la **ponderación TF-IDF (Term Frequency-Inverse Document Frequency)**.

El modelo TF-IDF establece que aquellos términos que ocurren frecuentemente en un documento pero que ocurren rara vez en otros documentos, serán más relevantes en el tema del documento en concreto.

La función **TF-IDF** que determina los pesos respecto a cada término t_k de un documento d_j siguiendo este método es la siguiente (Lops et al, 2011; Pazzani & Billsus, 2007):

$$TF - IDF(t_k, d_j) = TF(t_k, d_j) \times \log \frac{N}{n_k}$$

Siendo N el total de documentos y n_k , el número de documentos de la colección en el que el término t_k ocurre al menos una vez. Esto implica que los términos raros no sean menos relevantes que los frecuentes.

La función **TF (term frequency)** se calcula como el cociente entre la frecuencia en que el término t_k aparece en el documento d_j y la máxima frecuencia de cualquiera de los términos en ese documento. La multiplicación por el logaritmo pretende que se tenga en cuenta que los términos raros no sean menos relevantes. Por otra parte, para normalizar, y no favorecer a los documentos largos, frente a los cortos, se utiliza la siguiente expresión:

$$w_{k,j} = \frac{TF - IDF(t_k, d_j)}{\sqrt{\sum_{s=1}^{|T|} (TF - IDF(t_k, d_j))^2}}$$

Siendo T el conjunto completo de términos.

Para medir la similitud entre dos documentos se ha de utilizar una medida de similitud, y dado que el documento se está representando mediante un vector, para el cálculo de distancia entre vectores existen diversas medidas. Una medida muy utilizada es la similitud del coseno:

$$similitud(d_i, d_j) = \frac{\sum_k w_{ki} \cdot w_{kj}}{\sqrt{\sum_k w_{ki}^2} \cdot \sqrt{\sum_k w_{kj}^2}}$$

En sistemas de recomendación basados en VSM, los perfiles de usuario y los contenidos se representan como vectores de pesos calculados de forma análoga a lo que se ha explicado previamente. Una vez se tiene el vector del usuario esta medida de similitud de coseno puede ser utilizada para predecir el interés de un usuario en un ítem.

La recomendación de contenidos se puede tratar como una tarea de clasificación, donde los atributos de entrada de cada ejemplo corresponden a los metadatos o una representación de un contenido y la clase corresponde a la valoración de ese contenido por el usuario.

El problema de este tipo de sistemas es que basan la recomendación en la similitud de contenidos, con lo cual se está recomendando al usuario ítems similares y el usuario puede ya no estar interesado en ítems precisamente similares. Además, la similitud entre contenidos se basa en metadatos que no suelen contener información sobre aspectos subjetivos de los ítems.

Por ejemplo, en un sistema que oferta cursos, si un usuario ha realizado un curso sobre Inteligencia Artificial básica, el sistema le puede ofrecer cursos sobre Inteligencia Artificial avanzada. Podría darse el caso de que los contenidos sugeridos tengan en común la temática con el curso ya realizado pero, sin embargo, el primero es un curso muy bien explicado mientras que de los cursos ofertados algunos son complicados de seguir.

Este tipo de información subjetiva no se capta en estos sistemas y no se puede tener por tanto en cuenta. Por ello, existen sistemas recomendadores que utilizan una combinación de técnicas de filtrado colaborativo y técnicas de filtrado basado en contenidos.

En el ejemplo anterior, la información de similitud entre contenidos se podría complementar con información subjetiva extraída de valoraciones de usuarios. Además, si se utiliza información de usuarios similares para hacer recomendaciones, se podrá recomendar contenidos no necesariamente similares. Por otra parte, si un usuario es atípico, no es similar a otros usuarios, o no existe un suficiente número de usuarios en el sistema, la información basada en contenidos permitirá ofrecerle algún tipo de recomendación. Igualmente si un ítem nuevo no ha sido valorado, los sistemas basados en contenido pueden recomendarlo. Además este tipo de sistemas puede proporcionar explicaciones más sencillas al usuario del motivo de sus recomendaciones basadas en las características de los contenidos.

8.5. Referencias

Montaner, M., López, B. & de la Rosa, J.L. (2003). A Taxonomy of Recommender Agents on the Internet. *Artificial Intelligence Review*, 19, 285-330.

Lemire D., Boley H., McGrath, Ball M. (2005). Collaborative Filtering and Inference Rules for Context-Aware Learning Object Recommendation. *International Journal of Interactive Technology and Smart Education* 2(3).

Linden, G., Smith, B. & York, J. (2003). Amazon.com recommendations: item-to-item collaborative filtering. *IEEE Internet Computing*, 7(1), 76-80.

Lops, P., Gemmis, M., & Semeraro, G. (2011). Content-based Recommender Systems: State of the Art and Trends. En F. Ricci et al. (eds.). *Recommender Systems Handbook*, p. 73-105. Springer Science+Business Media.

Pazzani, M.J. & Billsus, D. (2007). Content-based Recommendation Systems. En P. Brusilovsky, A. Kobsa, and W. Nejdl (Eds.). *The Adaptive Web, LNCS 4321*, 325-341.

Lo + recomendado

No dejes de leer...

Taxonomía de agentes recomendadores

Montaner, M., López, B. & de la Rosa, J.L. (2003). A Taxonomy of Recommender Agents on the Internet. *Artificial Intelligence Review*, 19, 285-330.

Aunque el artículo presenta el estado de arte de los sistemas recomendadores hace 10 años, es muy interesante su lectura en la actualidad, ya que, en primer lugar, el artículo describe todas aquellas tareas necesarias para que un sistema realice la recomendación en función de su tipo. Para cada tarea, los autores hacen un recorrido de las diferentes técnicas aplicables, siendo muchas de ellas de actualidad. En este recorrido, el artículo tiene en cuenta 37 sistemas reales con diferentes propósitos: recomendadores web, recomendadores de noticias, música y películas, comercio electrónico, etc.

Accede al artículo desde el aula virtual o a través de la siguiente dirección web:

<http://eia.udg.edu/~blopez/publicacions/montaner-aireview03.pdf>

+ Información

A fondo

Sistemas recomendadores basados en contenidos

Lops, P., Gemmis, M., & Semeraro, G. (2011). Content-based Recommender Systems: State of the Art and Trends. En F. Ricci et al. (eds.). *Recommender Systems Handbook*, p. 73-105. Springer Science+Business Media

Artículo completo y claro que describe los sistemas recomendadores basados en contenidos, describiendo su arquitectura y recorriendo las diferentes técnicas utilizadas para representar contenidos, representar perfiles de usuarios, medir similitudes entre contenidos, etc. Además incluye temas recientes como el *social tagging*, relativo al marcado de documentos por los usuarios y los sistemas que recomiendan estos contenidos en base *tags* sociales.

Accede al artículo desde el aula virtual o a través de la siguiente dirección web:

<http://www.ics.uci.edu/~welling/teaching/CS77Bwinter12/handbook/ContentBasedRS.pdf>

Recomendación de productos basada en filtrado colaborativo

Tesis de doctorado de Vreixo Formoso López (Departamento de Tecnoloxías da Información e as Comunicacóns de la Universidade da Coruña) titulado «*Técnicas eficientes para la recomendación de productos basadas en filtrado colaborativo*», que describe y profundiza en los sistemas de recomendación basados en filtrado colaborativo, abordando diversos problemas que afectan a los algoritmos utilizados en estos sistemas.

Accede a la tesis desde el aula virtual o a través de la siguiente dirección web:

http://ruc.udc.es/dspace/bitstream/2183/10122/2/FormosoLopez_Vreixo_TD_2013.pdf

Medidas de asociación

Capítulo relativo a medidas de distancias y similitudes, elaborado por el Departamento de Estadística e Investigación Operativa de la Universidad de Granada, que incluye medidas de asociación entre variables y entre individuos. Es un capítulo muy completo comprendiendo medidas frecuentemente utilizadas en algoritmos de *clustering* o en otro tipo de sistemas como en los sistemas recomendadores.

Accede al capítulo desde el aula virtual o a través de la siguiente dirección web:

<http://www.ugr.es/~gallardo/pdf/cluster-2.pdf>

Webgrafía

Sistemas de recomendación

Sitio web de un curso sobre sistemas de recomendación donde están disponibles enlaces relativos a sistemas recomendadores y a *datasets* (conjuntos de datos). Además, se puede acceder a las diapositivas del curso que explican temas relativos a los sistemas de recomendación así como a propuestas de ejercicios con MATLAB.



Accede al curso desde el aula virtual o a través de la siguiente dirección web:

http://www.ics.uci.edu/~welling/teaching/CS77Bwinter12/CS77B_w12.html

Bibliografía

Bhasker, B. & Sri Kumar, K. (2010). *Recommender Systems in e-Commerce. Methodologies and Applications of Data Mining*. New Delhi: McGraw Hill.

Jannach, D., Zanker, M., Felfernig, A. & Friedrich, G. (2011). *Recommender Systems: An Introduction*. Cambridge University Press.

Ricci, F., Rokach, L., Shapira, B. & Kantor, P.B. (Eds). (2011). *Recommender Systems Handbook*. Springer Science+Business Media.